

3D-VLA 入门导读

机器人如何“看懂三维世界、想象目标状态、再规划动作”


3D perception

world model

robot action

面向没有 VLA 背景的组员

目标：听完能讲清楚问题、方法和证据边界



图：3D-VLA 的“目标想象—动作生成”管线

先理解 VLA：把机器人控制写成“下一段 token”

视觉观测 I_t + 语言指令 x



动作 token 序列 $a_{t:t+H}$

- ▶ Vision：相机看到什么
- ▶ Language：人希望机器人做什么
- ▶ Action：机械臂位置、旋转与夹爪开合

RT-2 的关键做法

把机器人动作离散成文本 token，让视觉语言模型同时学习网页知识与机器人轨迹。


但普通 VLA 多数依赖 2D 图像，
并直接从观测预测动作。

3D-VLA 针对两个缺口

	常见 2D VLA	3D-VLA 的选择
空间理解	图像像素提供间接线索	RGB-D、点云和 3D 包围盒明确表达距离与位置
动作生成	观测直接映射到动作	先生成目标图像或目标点云，再据此预测动作
世界动态	隐含在策略参数中	用生成模型显式“想象”任务完成后的状态
输出形式	语言或动作	语言、位置、图像、深度、点云与动作 token

核心假设：目标状态是连接语言意图与机器人动作的中间表示。

总体架构：理解场景、想象目标、生成动作



1. 场景编码

多视角图像形成 3D 特征，
经 Q-Former 接入语言模
型。

2. 目标想象


LLM 的输出经 projector 条
件化扩散模型，生成目标
图像或点云。

3. 机器人控制

目标状态再次送入模型，
输出离散动作 token。

一个模型覆盖三类任务

3D-VLA: A 3D Vision-Language-Action Generative World Model



推理与定位

多模态目标生成

机器人规划

数据构建：从已有视频补出 3D 监督

1. 汇集机器人操作与人—物交互数据
2. 用 ZoeDepth 补深度，用 RAFT 对齐视频帧
3. 用 Grounded-SAM 提取目标物体掩码，再投影为点云与 3D 包围盒
4. 用模板和语言模型生成问答、定位、目标生成与动作预测指令

2M

3D—语言—动作数据对


316k

使用的原始 episode

论文汇总了 12 个 Open-X 子集，并加入 Dobb-E、RH20T、RLBench、CALVIN 与 HOI 数据。

3D 表征提供“在哪里”和“有多远”

3D-VLA: A 3D Vision-Language-Action Generative World Model



点云

每个点带有 (x, y, z) 坐标，可直接表达物体的三维形状和距离。

3D 包围盒

用 6 个离散位置 token 表示轴对齐包围盒，帮助模型定位被操作物体。

重要限制

真实相机的深度尺度和噪声并不统一，点云质量会影响控制精度。

交互 token：把物体、空间和动作塞进语言序列

场景与物体

- ▶ `<scene> ... </scene>`
- ▶ `<obj> apple </obj>`
- ▶ `<loc0-255>` 表示 3D 坐标

User: Find some snacks for me.

Robot: I should

`<img> pick up <obj> chip bag </obj>`

`<loc...> </img>`


动作

- ▶ 位置 `<aloc0-255>`
- ▶ 旋转 `<arot0-255>`
- ▶ 夹爪 `<gripper0/1>`

离散化让同一个语言模型接口同时处理语义、空间位置与机器人动作，但也会牺牲连续控制的精度。

生成式世界模型：先画出任务完成后的样子

3D-VLA: A 3D Vision-Language-Action Generative World Model



RGB-D 目标生成

Stable Diffusion 1.4 接收初始 RGB-D 与指令，编辑出目标 RGB-D。

点云目标生成

Point-E 接收初始点云与指令，生成任务完成后的点云。

训练分成三步，最后只对齐必要参数

01

适配扩散模型

在机器人数据上训练
RGB-D 编辑与点云生成，
缩小互联网图像与机器人
场景的域差异。

02

训练多模态 LLM

基于 BLIP-2 FlanT5-XL，
训练问答、描述、定位与动
作预测。

03

跨模态对齐

联合优化特殊 token、
projector 与扩散模型
LoRA，同时最小化语言损
失和去噪损失。

工程代价不小：论文各阶段使用了数百张 V100 GPU。

证据一：3D 数据显著改善推理与定位

语言任务代表结果

任务与指标	BLIP-2	3D-VLA
Embodied QA, BLEU-4	15.48	26.80
Task caption, BLEU-4	3.16	34.88
What-if QA, BLEU-4	0.06	29.38
Dense caption, EM@1	13.10	39.49

3D 定位结果

方法	IoU	Acc@25
Kosmos-2 + GT depth	10.92	12.73
CoVLM + GT depth	19.81	25.39
3D-VLA	29.33	42.26

解读边界：这些任务主要使用 held-in 数据，说明 3D 监督有效，不等同于开放世界泛化。

证据二：目标想象帮助部分机器人任务

RLBench 成功率 (%)

方法	放刀	取伞	拿杯	未见杯
无目标生成	58	68	34	24
3D-VLA	68	80	40	28

目标状态对需要定位与辨别目标的任务帮助更明显。

图像目标生成中，3D-VLA 取得 PSNR 17.21、SSIM 0.636；FID 并非所有方法中最低，因此应分指标阅读。

CALVIN 长序列任务

方法	完成 1 个	完成 3 个	平均长度
MCIL	28.2	0.3	0.31
3D-VLA	44.7	8.1	0.71

仍有限：连续完成 5 个任务的成功率为 0，RLBench 使用开环执行。

论文明确承认的四类局限

精细控制不足

3D 特征与离散动作 token 难以支持小物体的精确抓取。

目标图像会“幻觉”

纹理或形状变化、物体消失、生成错误任务结果或完全不变化。

真实深度噪声

不同场景尺度不一致，深度图与点云质量下降。

数据质量长尾

不同数据集的标注和图像质量差异明显，表现随数据源波动。

讨论时要区分：生成了“合理目标图”与机器人真正闭环完成任务。

带走的三个认识与讨论问题

三个认识

1. 3D 表征把空间关系从隐式线索变成显式监督。
2. 目标状态生成给动作预测增加了可解释的中间变量。
3. 论文证明了方法潜力，但真实闭环控制和跨场景泛化仍未充分验证。

建议讨论

- ▶ 目标图像和目标点云，哪个更适合控制？
- ▶ 离散动作 token 如何兼顾语义与精度？
- ▶ 如果复现，最小可行实验应选哪一部分？

下一步：先跑目标图像生成 demo，再设计小规模消融实验。