


3D-VLA 基础入门

从机器人学习、VLA、3D 表征到生成式世界模型

面向 CS / ECE 大三学生

不要求机器人学、3D 视觉或大模型背景



3D-VLA 的目标想象与机器人控制管线

今天要建立的知识地图

先建立基础

1. 机器人策略在学习什么
2. Vision、Language、Action 各自是什么
3. 模仿学习如何把演示变成策略
4. 2D VLA 的能力与不足

再进入 3D-VLA

5. 深度图、点云和 3D 包围盒
6. 世界模型与目标状态想象
7. 3D-VLA 的数据、token 和架构
8. 实验证据、局限与复现入口

目标：能用自己的话解释“为什么需要 3D-VLA”。

机器人策略：从观测和任务得到动作

当前观测 o_t + 任务指令 x

$$\Downarrow \pi_{\theta}(a_t \mid o_t, x) \Downarrow$$

下一步动作 a_t

观测

RGB 图像、深度、关节状态或力传感器读数

任务

“拿起红杯子” “打开抽屉”
等自然语言

动作

末端位置、旋转、夹爪开合或关节控制量

VLA 的三个字母分别解决什么问题

	输入或输出	要回答的问题	例子
Vision	图像或视频	场景中有什么，物体在哪里	红杯在桌面左侧
Language	文本指令	人希望机器人完成什么	把红杯放进水槽
Action	控制序列	机械臂下一步如何运动	移动、旋转、闭合夹爪

VLA 希望用一个模型把**感知**、**语义**和**控制**连接起来。

VLA 通常从机器人演示中学习

训练数据是一段段轨迹

$$\tau = (o_1, x, a_1, o_2, x, a_2, \dots, o_T, x, a_T)$$

模型学习在给定观测和指令时，预测演示者采取的动作：

$$\min_{\theta} - \sum_t \log \pi_{\theta}(a_t \mid o_t, x)$$

直观理解

- ▶ 人先示范如何完成任务
- ▶ 模型模仿每个时刻的动作
- ▶ 部署时根据新观测继续预测

难点：机器人一旦偏离演示轨迹，后续观测也会变得陌生。

RT-2 的关键思想：把动作也写成 token

图像 + 指令



语言模型生成动作 token

动作可以离散成一串编号，例如位置、旋转和夹爪状态各自对应若干 token。

这样做的好处

- ▶ 复用视觉语言模型的知识
- ▶ 文本与机器人数据可以共同训练
- ▶ 一个接口同时输出语言和动作

代价：离散化会损失连续控制精度。


为什么仅看 2D 图像还不够

挑战	2D 图像中的困难	控制需要的信息
距离	同样大小的物体可能远近不同	抓取点与机械臂之间的真实距离
遮挡	看不到被挡住的几何结构	物体是否可抓、路径是否会碰撞
视角变化	像素位置随相机移动而变化	相对稳定的三维坐标
空间语言	“最远”“上方”“抽屉里面” 含义模糊	可计算的三维关系

机器人在三维世界中行动，因此空间表征必须服务于控制。

三个常见的 3D 表征

3D-VLA: A 3D Vision-Language-Action Generative World Model



深度图 RGB-D

每个像素除了颜色，还带有到相机的距离。

点云 Point Cloud

把像素投影到三维坐标，得到很多 (x, y, z) 点。3D 包围盒

用一个长方体近似物体的位置和尺寸，便于定位目标。

世界模型：预测“如果这样做，会发生什么”

当前状态 s_t + 候选动作 a_t $\longrightarrow$ 预测状态 $\hat{s}_{t+1}$

普通策略

直接从当前观测输出动作。模型可能学会操作，但内部依据难以观察。

3D-VLA 的做法

先生成任务完成后的目标图像或点云，再用目标状态帮助动作预测。

“想象目标状态”成为语言意图与动作之间的中间变量。

3D-VLA 在普通 VLA 上增加了什么

01

三维场景特征

多视角图像、深度和点云提供空间信息。

02

交互 token

统一表示场景、物体位置、目标模态和机器人动作。

03

生成式目标状态

扩散模型生成目标 RGB-D 或点云，辅助规划。

论文的一句话主张

机器人如果理解三维场景，并能想象任务完成后的状态，就能更好地推理和规划动作。

3D-VLA 学习三大类任务

3D-VLA: A 3D Vision-Language-Action Generative World Model



推理与定位

问答、任务描述、3D 检测

目标状态生成

RGB、深度与点云

动作规划

RLBench 与 CALVIN

数据构建：从现有视频补出 3D 监督

1. 收集机器人操作与人—物交互视频
2. 用 ZoeDepth 估计深度，用 RAFT 对齐视频帧
3. 用 Grounded-SAM 找到被操作物体
4. 将 RGB-D 投影成点云与 3D 包围盒
5. 生成问答、定位、目标生成和动作预测指令

2M

3D—语言—动作数据对

316k

使用的原始 episode 来自真实

机器人、仿真环境和人类交互数据。

交互 token：让语言模型读写机器人变量

场景和物体

- ▶ `<scene> ... </scene>`
- ▶ `<obj> apple </obj>`
- ▶ `<loc0-255>` 表示 3D 位置

机器人动作

- ▶ `<aloc0-255>`：位置
- ▶ `<arot0-255>`：旋转
- ▶ `<gripper0/1>`：夹爪

示例输出


`<img> pick up chip bag </obj> </img>`

为什么有用

同一个模型接口可以处理语义、三维位置、目标模态和动作。**为什么有风险**

连续空间被量化成有限 token，精细控制会受影响。

整体架构：先理解，再想象，最后行动



1. 理解场景

3D 特征经 Q-Former 接入语言模型。

2. 想象目标

Projector 将 LLM 特征送入扩散模型。

3. 生成动作

目标状态再次帮助模型预测动作 token。

训练流程分为三个阶段

01

训练目标生成器

在机器人数据上训练
RGB-D 编辑与点云扩散模型。

02

训练多模态 LLM

学习问答、描述、定位和
动作预测等语言任务。

03

对齐两类模型

更新特殊 token、projector
与扩散模型 LoRA 参数。

论文训练规模很大，完整复现并不适合作为第一次上手任务。

实验结果说明了什么

推理与 3D 定位

指标	BLIP-2	3D-VLA
Embodied QA, BLEU-4	15.48	26.80
Task caption, BLEU-4	3.16	34.88
3D localization, Acc@25	25.39*	42.26

* CoVLM 使用真实深度进行 2D 到 3D 投影。

RLBench 成功率 (%)

方法	放刀	取伞	拿杯	未见杯
无目标生成	58	68	34	24
3D-VLA	68	80	40	28

目标想象对依赖目标位置和外观的任务
更有帮助。

阅读边界：推理任务主要使用 held-in 数据，动作实验规模有限，不能直接等同于开放世界泛化。

结论、局限与下一步

今天应带走的结论

1. VLA 把视觉、语言和机器人动作放进一个模型。
2. 3D 表征提供距离、位置和几何关系。
3. 3D-VLA 先生成目标状态，再辅助动作预测。

论文仍未解决

- ▶ 小物体的精确控制
- ▶ 生成模型的物体消失与错误变化
- ▶ 真实深度噪声和尺度不一致
- ▶ 长序列闭环执行与开放世界泛化

建议起点：先运行目标图像生成 demo，再比较有无目标状态的动作预测。